

# 基于 DINOv2 的深度图场景分类

丁驿

武汉理工大学国际教育学院  
Email: dyvertin@outlook.com

**Abstract**—深度图场景分类是室内机器人和隐私保护视觉系统中的重要任务，然而深度数据缺乏 RGB 图像那样的大规模预训练模型。本文证明，仅在 RGB 图像上自监督预训练的 DINOv2 视觉 Transformer 可以作为深度图场景分类的有效特征提取器。使用冻结的 DINOv2-Base 骨干网络配合轻量线性分类头（10K 参数），我们在 NYU Depth V2 数据集（13 类室内场景）上达到 55.5% 的 Top-1 准确率。这一结果与需要全网络微调的深度专用方法（58–60%）相竞争，而可训练参数仅为其 0.02%。我们还发现数据增强带来了 20.5 个百分点的提升（基线 35.0% → 55.5%）。我们的结果表明，自监督 RGB 预训练特征可以有效泛化到纯深度输入的场景分类任务。

**Index Terms**—场景分类，深度图，DINOv2，线性探测，迁移学习，NYU Depth V2

## I. 引言

深度图提供了场景的紧凑几何表示，在视觉任务上具有优于 RGB 图像的若干优势。它们自然地抑制了可能成为分类混淆因素的颜色和纹理变化，并通过不记录个体外观来提供固有的隐私保护 [6]。这些特性使得基于深度图的场景分类在室内机器人、环境智能和人体活动分析中特别有吸引力。

与 RGB 图像不同，深度数据缺乏专门的大规模预训练分类模型。现有的深度图场景分类方法通常依赖于手工设计的深度编码如 HHA（水平视差、地面高度、重力方向角）[8]，随后微调 ImageNet 预训练的 CNN。这些方法虽然有效，但需要全网络微调和针对模态的预处理。

自监督视觉表示学习的近期进展——特别是 DINOv2 [1]——产生了强大的通用特征提取器，能够捕捉丰富的语义信息。DINOv2 在 1.42 亿 RGB 图像上通过自蒸馏框架训练，产生编码物体形状、纹理和空间关系的特征。一个自然的问题是：这种在 RGB 上预训练的特征能否泛化到纯深度输入的场景分类任务？

本文对此给予肯定回答。我们的主要贡献如下：

- 1) 我们证明，冻结的 DINOv2-Base 骨干网络配合线性分类头（10K 参数）在 NYU Depth V2 13 类基准上达到 55.5% 的 Top-1 准确率，与需要全网络微调的深度专用方法相竞争。
- 2) 我们展示了数据增强带来的 20.5 个百分点提升（35.0% → 55.5%），突显了增强策略在小样本深度分类中的关键作用。
- 3) 我们提供了与先前 CLIP 跨模态方法（25.3%）以及现有深度分类方法的系统对比，证明了自监督 RGB 特征可以有效地迁移到纯深度输入。

## II. 相关工作

### A. 深度图分类

NYU Depth V2 数据集 [3] 是室内场景理解的主要基准。Gupta 等 [8] 提出的 HHA 编码将深度图转换为适合 ImageNet 预训练 CNN 的 3 通道表示，在 13 类分类上

达到约 50%。RedNet [?] 扩展了这一方向，使用双流残差架构进行 RGB-D 融合，其深度分支达到约 56%。近期 Transformer 方法被应用于深度场景理解，但大多关注 RGB-D 融合或密集预测任务，而非纯深度分类。

与这些方法不同，我们的方法使用冻结骨干网络配合线性分类头，无需全网络微调。

### B. DINOv2 自监督特征

DINOv2 [1]（无标签蒸馏 v2）由 Meta FAIR 提出，从 1.42 亿精选图像中学习视觉表示，无需人工标注。其自蒸馏框架产生的特征捕捉语义内容——物体形状、纹理模式和空间关系——使其高度可迁移到各种下游任务。ViT-B/14 变体使用 14×14 的 Vision Transformer 架构，处理 518×518 的输入。DINOv2 特征在图像分类、分割和检索等任务的线性探测评估协议 [13] 下表现出色。

## III. 方法

### A. 总体框架

我们的实验框架遵循线性探测范式 [13]，即使用冻结的预训练骨干网络作为固定特征提取器，仅在其上训练线性分类头。这一方法直接衡量预训练特征的质量：如果特征在下游任务是线性可分的，线性探测将表现良好。

### B. 骨干网络：DINOv2-Base

我们使用 DINOv2-Base 模型（ViT-B/14，768 维隐藏状态，12 个 Transformer 块，12 个注意力头），冻结所有参数。输入分辨率为 518×518 像素。原始为单通道的深度图被复制为三通道以匹配模型预期的输入格式。特征从最后一层的 [CLS] 标记提取并做 L2 归一化。

图 1 展示了整体框架。




Fig. 1: 整体框架。冻结的 DINOv2-Base 骨干网络从深度图中提取 [CLS] 特征，由 Linear(768, 13) 分类头分类。

### C. 线性分类器

一个线性层将 768 维 [CLS] 特征映射到 13 类 logits：

$$\mathbf{z} = \mathbf{W}\mathbf{f} + \mathbf{b}, \quad \mathbf{W} \in \mathbb{R}^{13 \times 768}, \quad \mathbf{b} \in \mathbb{R}^{13}.$$

可训练参数总数为  $13 \times 768 + 13 = 9,997$ ——约 10K。这一极简分类器确保任何性能差异归因于冻结骨干网络的特征质量。

#### D. 损失函数

我们采用标签平滑交叉熵损失， $\varepsilon = 0.1$ ：

$$\mathcal{L} = -\frac{1}{N} \sum_{i=1}^N \sum_{c=1}^{13} q_c^{(i)} \log p_c^{(i)},$$

其中真实类别的  $q_c = 1 - \varepsilon$ ，其他类别的  $q_c = \varepsilon / (13 - 1)$ 。标签平滑减轻了过置信问题，提升了小数据集的泛化能力。

#### E. 训练细节

表 I 汇总了超参数设置。

TABLE I: 训练配置。

| 参数   | 取值                                    |
|------|---------------------------------------|
| 骨干网络 | DINOv2-Base (冻结)                      |
| 分类头  | Linear(768, 13)                       |
| 损失函数 | 标签平滑交叉熵 ( $\varepsilon = 0.1$ )       |
| 优化器  | AdamW                                 |
| 学习率  | $2 \times 10^{-3}$                    |
| 权重衰减 | $1 \times 10^{-4}$                    |
| 调度器  | CosineAnnealingLR ( $T_{max} = 100$ ) |
| 训练轮数 | 100                                   |
| 批大小  | 16                                    |
| 数据增强 | 随机水平翻转 + 仿射变换 + 颜色抖动                  |

#### F. 数据集：NYU Depth V2

NYU Depth V2 数据集 [3] 包含 1,449 组 RGB-D 室内场景配对。原始标注包含 27 种场景类型，许多是同一类别的语义变体。我们按照先前工作 [7], [8] 将其合并为 13 个语义类别：浴室、卧室、书店、教室、餐厅、家具店、家庭办公室、厨房、洗衣房、图书馆、客厅、办公室、书房。

数据集使用固定随机种子 (42) 划分为 900 训练、200 验证和 249 测试样本。平均每类仅 69 张图像，使其成为具有挑战性的迁移学习基准。

### IV. 实验

#### A. 主要结果

表 II 展示了我们的主要结果和参考基线对比。

TABLE II: NYU13 验证集上的主要结果。

| 方法                      | 骨干网络                    | 参数量        | 精度           |
|-------------------------|-------------------------|------------|--------------|
| 随机猜测                    | —                       | —          | 7.7%         |
| CLIP + 适配器 [12]         | CLIP ViT-B/32           | 528K       | 25.3%        |
| DINOv2 (无增强, 25 轮)      | DINOv2-Base             | 10K        | 35.0%        |
| <b>本文方法</b>             | <b>DINOv2-Base (冻结)</b> | <b>10K</b> | <b>55.5%</b> |
| 深度分类 SOTA:              |                         |            |              |
| Gupta HHA + AlexNet [8] | AlexNet (微调)            | ~60M       | ~50%         |
| RedNet 深度分支 [?]         | ResNet (微调)             | ~25M       | ~56%         |

我们的冻结 DINOv2 骨干网络配合 10K 参数线性头达到 55.5% 验证精度。这一结果与 RedNet 深度分支 (约 56%) 相竞争，而 RedNet 需要微调数百万参数的完整 ResNet 网络。相比先前 CLIP 跨模态方法 (25.3%)，我们的方法精度翻倍以上。

#### B. 数据增强的影响

数据增强在我们的流程中起着关键作用。在增强实施前的早期实验中，相同 DINOv2 骨干网络在 25 轮训练后仅达 35.0%——与增强后的 100 轮结果存在 20.5 个百分点的差距。

表 III 量化了各组件的贡献。

TABLE III: 各组件对精度提升的贡献。

| 配置                  | 验证精度         | 提升            |
|---------------------|--------------|---------------|
| CLIP ViT-B/32 (基线)  | 25.3%        | —             |
| DINOv2 + 无增强 (25 轮) | 35.0%        | +9.7%         |
| DINOv2 + 增强 + 100 轮 | <b>55.5%</b> | <b>+20.5%</b> |

增强带来的 20.5% 提升几乎与从 CLIP 切换到 DINOv2 的总增益 (30.2%) 相当。这一发现强调：对于小样本深度分类，简单的数据增强策略是高杠杆率的干预措施。

#### C. 训练动态

图 2 展示了训练和验证曲线。




Fig. 2: 训练动态。左：验证准确率。右：损失曲线。

模型稳定收敛，约在第 43 轮达到 55.5% 并维持至第 100 轮。验证损失提前稳定，确认线性探测已达到冻结特征表示能力的极限。

#### D. 与 CLIP 方法的对比

在采用 DINOv2 线性探测之前，我们使用 CLIP ViT-B/32 [?] 配合 MLP 适配器通过 NT-Xent 对比损失进行了实验。该方法通过 RGB 与深度表示之间的跨模态对比学习将 CLIP 的 512 维视觉特征映射到对齐的嵌入空间。尽管经过了广泛的超参数调优 (学习率、温度、适配器深度、Dropout)，最佳 CLIP 配置仅达到 25.3% 的 13 类验证精度。

CLIP 方法的根本限制在于，其视觉编码器为图像-文本对齐而预训练，产生的特征不适合纯深度输入。而 DINOv2 的自监督特征捕捉丰富的空间和结构信息，自然地迁移到深度图。

TABLE IV: CLIP 方法与 DINOv2 方法的对比。

| 维度       | CLIP + 适配器     | 本文方法 (DINOv2) |
|----------|----------------|---------------|
| 骨干网络     | CLIP ViT-B/32  | DINOv2-Base   |
| 训练目标     | 对比学习 (NT-Xent) | 交叉熵           |
| 可训练参数    | 528K           | 10K           |
| 输入分辨率    | 224×224        | 518×518       |
| NYU13 精度 | 25.3%          | <b>55.5%</b>  |

## V. 讨论

### A. DINOv2 为何能在深度图上工作?

DINOv2 在预训练期间从未见过深度图——它仅在 RGB 图像上训练。但其特征在纯深度场景分类上取得了有竞争力的结果。我们将此归因于 DINOv2 自监督学习目标的特性。

DINOv2 通过自蒸馏结合掩码图像建模和视角一致性约束进行训练。这迫使模型学习捕捉场景级语义的特征：物体形状、空间布局和环境功能。这些语义特征在很大程度上不受输入模态影响——无论表示为 RGB 值还是深度值，“卧室”都具有 DINOv2 特征可以识别的特征性空间结构。

### B. 效率优势

我们方法的一个显著特点是其参数效率。仅使用 10K 可训练参数（一个线性层），我们就达到了需要全网络微调 25M–60M 参数的方法的性能。这使得我们的方法在资源受限的环境和快速原型开发中非常实用。

### C. 局限性

本研究存在若干局限性。首先，数据集（1,449 张图像）相对较小，结论可能不推广到 SUN RGB-D 等更大数据集。其次，我们仅评估冻结特征；微调 DINOv2 骨干网络可能获得更高精度。第三，线性探测协议虽然评估上干净，但可能未充分利用 DINOv2 特征的完整表示能力。

## VI. 结论

我们证明了仅在 RGB 图像上自监督预训练的 DINOv2 视觉 Transformer 可以作为深度图场景分类的有效特征提取器。使用冻结的 DINOv2-Base 骨干网络配合轻量线性分类头（10K 参数），我们在 NYU Depth V2 13 类基准上达到 55.5% 的 Top-1 准确率——与需要全网络微调的深度专用方法相竞争。

我们的主要发现如下：

- 1) 自监督 RGB 预训练特征 (DINOv2) 可以有效地泛化到纯深度输入的场景分类。
- 2) 数据增强带来 20.5 个百分点的提升，远超架构选择的影响。
- 3) 仅用 10K 可训练参数，我们的方法即达到需要数百万参数和全网络微调的方法的性能。

这些结果确立了 DINOv2 作为深度图场景分类的强基线，凸显了自监督 RGB 特征在非 RGB 传感器模态上的潜力。未来工作应探索微调机制、更大深度数据集以及其他传感器类型（如热红外）。

## REFERENCES

- [1] M. Oquab, T. Darcet, T. Moutakanni, *et al.*, “DINOv2: Learning Robust Visual Features without Supervision,” *Transactions on Machine Learning Research*, 2024.
- [2] N. Silberman, D. Hoiem, P. Kohli, and R. Fergus, “Indoor Segmentation and Support Inference from RGBD Images,” in *Proc. European Conference on Computer Vision (ECCV)*, 2012.
- [3] S. Gupta, R. Girshick, P. Arbeláez, and J. Malik, “Learning Rich Features from RGB-D Images for Object Detection and Segmentation,” in *Proc. European Conference on Computer Vision (ECCV)*, 2014.
- [4] K. He, G. Gkioxari, P. Dollár, and R. Girshick, “Mask R-CNN,” in *Proc. IEEE Int. Conf. Computer Vision (ICCV)*, 2017.
- [5] A. Wang, J. Lu, J. Cai, *et al.*, “Unsupervised Joint Feature Learning for Zero-shot Scene Classification,” arXiv:1609.00245, 2016.
- [6] J. Jiang, L. Zheng, F. Luo, and Z. Zhang, “RedNet: Residual Encoder-Decoder Network for Indoor RGB-D Semantic Segmentation,” arXiv:1806.01054, 2018.
- [7] A. Radford, J. W. Kim, C. Hallacy, *et al.*, “Learning Transferable Visual Models From Natural Language Supervision,” in *Proc. Int. Conf. Machine Learning (ICML)*, 2021.
- [8] G. Alain and Y. Bengio, “Understanding intermediate layers using linear classifier probes,” in *ICLR Workshop*, 2017.
- [9] Mar-Ding, “Depth Scene Classification: Project Summary,” Technical report, 2026. <https://github.com/Mar-Ding/depth-scene-classification>