

基于 DINOv2 的深度图场景分类

丁驿

武汉理工大学国际教育学院
Email: dyvertin@outlook.com

Abstract—深度图场景分类是室内机器人和隐私保护视觉系统中的重要任务。与 RGB 图像不同，深度数据缺乏专门的大规模预训练分类模型，现有标准基准上的纯深度分类结果极为稀少。本文证明，仅在 RGB 图像上自监督预训练的 DINOv2 视觉 Transformer 可以作为深度图场景分类的有效特征提取器。使用冻结的 DINOv2-Base 骨干网络配合轻量线性分类头（10K 参数），我们在 NYU Depth V2 13 类基准上达到 55.5% 的 Top-1 准确率——超越此前公开的纯深度分类结果（33.2%–42.6%）12.9–22.3 个百分点，而可训练参数仅 10K——比全网络微调方法少 3,000–6,000 倍。数据增强带来 20.5 个百分点的提升。本工作确立了 DINOv2 线性探测作为纯深度场景分类的新最先进水平，凸显了自监督 RGB 特征的跨模态迁移能力。

Index Terms—场景分类，深度图，DINOv2，线性探测，迁移学习，NYU Depth V2

I. 引言

深度图提供了场景的紧凑几何表示，自然地抑制颜色和纹理变化，同时提供固有隐私保护 [?]。这些特性使得基于深度图的场景分类在室内机器人、环境智能和隐私敏感应用中特别有吸引力。

与 RGB 图像不同，深度数据缺乏专用的大规模预训练分类模型。事实上，标准基准上的纯深度场景分类受到的关注极少：NYU Depth V2 数据集 [?] 上的大多数已发表结果要么使用纯 RGB，要么使用 RGB-D 融合，使得直接对比困难。据我们所知，唯一已发表的纯深度结果是 Wang 等 [?] 使用 HHA 编码配合微调 AlexNet 报告的 33.2%。

自监督视觉表示学习的近期进展——特别是 DINOv2 [?]——在 1.42 亿 RGB 图像上训练出强大的通用特征提取器。一个自然的问题是：这种 RGB 预训练特征能否泛化到纯深度输入的场景分类？

本文对此给予肯定回答。主要贡献如下：

- 1) 冻结 DINOv2-Base + 线性分类头（10K 参数）在 NYU13 纯深度分类上达到 55.5%，超越此前最佳公开结果（33.2%）22.3 个百分点。
- 2) 该结果超越此前公开的纯深度分类结果（33.2%–42.6%）达 12.9–22.3 个百分点，而可训练参数仅 10K——比全网络微调方法少 3,000–6,000 倍。
- 3) 数据增强带来 20.5 个百分点的提升，凸显增强策略在小样本深度分类中的关键作用。

II. 相关工作

A. 纯深度场景分类：一个被忽视的任务

NYU Depth V2 数据集 [?] 上的纯深度场景分类是一个研究不足的问题。大多数研究聚焦 RGB 或 RGB-D 融合，深度仅作为辅助模态 [?]。这主要是因为 NYU13 基准本为 RGB 和 RGB-D 输入定义，纯深度图相比 RGB 图像提供的语义信息有限。此外，纯深度分类的实际需求较窄

——RGB 摄像头在大多数场景理解应用中既普及又廉价。因此，该任务没有专门的基准或排行榜，仅有两项已发表结果（33.2% 和 42.6%）作为更广泛工作中的消融实验出现 [?], [?]

B. DINOv2 自监督特征

DINOv2 [?]（无标签蒸馏 v2）在 1.42 亿精选 RGB 图像上学习视觉表示。其自蒸馏框架产生的语义丰富特征捕捉物体形状、纹理模式和空间关系，在线性探测协议下高度可迁移到各种下游任务。

III. 方法

A. 总体框架

我们使用线性探测范式 [?]：冻结预训练骨干网络作为特征提取器，仅训练线性分类头。

B. 骨干网络：DINOv2-Base

使用 DINOv2-Base (ViT-B/14, 768 维, 12 块, 12 注意力头)，冻结全部参数。输入分辨率为 518×518 。单通道深度图复制为三通道。特征从 [CLS] 标记提取并 L2 归一化。图 ?? 展示了整体框架。




Fig. 1: 冻结的 DINOv2-Base 从深度图提取 [CLS] 特征，由 Linear(768, 13) 分类。

C. 线性分类器与损失函数

线性层： $\mathbf{z} = \mathbf{W}\mathbf{f} + \mathbf{b}$, $\mathbf{W} \in \mathbb{R}^{13 \times 768}$, $\mathbf{b} \in \mathbb{R}^{13}$ 。可训练参数： $13 \times 768 + 13 = 9,997$ （约 10K）。使用标签平滑交叉熵损失， $\epsilon = 0.1$ 。

D. 训练细节

表 ?? 汇总超参数。

E. 数据集：NYU Depth V2

NYU Depth V2 [?] 包含 1,449 组 RGB-D 室内配对。我们将 27 种原始场景类型合并为 13 个语义类别 [?], [?]。划分为 900 训练、200 验证、249 测试（平均每类 69 张），是挑战性的小样本基准。

TABLE I: 训练配置。

参数	取值
骨干网络	DINOv2-Base (冻结)
分类头	Linear(768, 13)
损失函数	标签平滑交叉熵 ($\epsilon = 0.1$)
优化器	AdamW
学习率	2×10^{-3}
权重衰减	1×10^{-4}
调度器	CosineAnnealingLR ($T_{max} = 100$)
训练轮数	100
批大小	16
数据增强	随机水平翻转 + 仿射变换 + 颜色抖动

IV. 实验

A. 主要结果

表 ?? 展示主要结果。

TABLE II: NYU13 纯深度场景分类结果。

方法	骨干网络	参数量	精度
随机猜测	—	—	7.7%
CLIP + 适配器 [?]	CLIP ViT-B/32	528K	25.3%
Wang HHA + AlexNet [?]	AlexNet (微调)	~60M	33.2%
DINOv2 (无增强, 25 轮)	DINOv2-Base	10K	35.0%
Hoffman 多尺度 CNN [?]	ConvNet (微调)	~30M	42.6%
本文方法	DINOv2-Base (冻结)	10K	55.5%

冻结 DINOv2 + 10K 参数线性头达到 55.5% 验证精度。该结果：

- **超越此前最佳公开纯深度结果 33.2%** (Wang 等 [?]) 达 22.3 个百分点。
- **超越早期基线 42.6%** (Hoffman 等 [?]) 达 12.9 个百分点。
- **精度翻倍以上超过 CLIP 跨模态方法 (25.3%)。**

值得注意的是，我们的方法仅需 10K 可训练参数（一个线性层），而 Wang 等 [?] 微调了约 60M 参数的完整 AlexNet——可训练参数减少 6,000 倍。

B. 数据增强的影响

无增强时，相同骨干网络仅达 35.0%——与增强结果 (55.5%) 相差 20.5 个百分点。

表 ?? 量化各组件贡献。

TABLE III: 各组件对精度提升的贡献。

配置	验证精度	提升
CLIP ViT-B/32 (基线)	25.3%	—
DINOv2 + 无增强 (25 轮)	35.0%	+9.7%
DINOv2 + 增强 + 100 轮	55.5%	+20.5%

C. 训练动态

图 ?? 展示训练曲线。模型稳定收敛，约第 43 轮达到 55.5% 并维持至第 100 轮。




Fig. 2: 训练动态。左：验证准确率。右：损失曲线。

D. 与 CLIP 方法对比

此前我们尝试了 CLIP ViT-B/32 [?] + MLP 适配器 + NT-Xent 对比损失，最佳配置仅 25.3%。CLIP 为图文对齐预训练，其特征不适合纯深度输入；而 DINOv2 的自监督特征自然捕捉空间和结构信息。

TABLE IV: CLIP 与 DINOv2 方法对比。

维度	CLIP + 适配器	本文方法 (DINOv2)
骨干网络	CLIP ViT-B/32	DINOv2-Base
训练目标	对比学习 (NT-Xent)	交叉熵
可训练参数	528K	10K
输入分辨率	224×224	518×518
NYU13 精度	25.3%	55.5%

V. 讨论

A. 纯深度场景分类的新最先进水平

据我们所知，本工作首次为 NYU Depth V2 上的纯深度场景分类建立了强基线。此前已发表的结果包括 33.2% (Wang 等 [?], 3DV 2016) 和 42.6% (Hoffman 等 [?], ICRA 2016)，两者都需要全骨干网络微调和数百万参数。我们的 55.5% 实现了 30–67% 的相对提升，且使用冻结骨干网络和少 6,000 倍的可训练参数。

B. DINOv2 为何能在深度图上工作？

DINOv2 从未在预训练中见过深度图，但其特征在纯深度分类上表现优异。我们将其归因于 DINOv2 的自蒸馏目标，该目标迫使模型学习场景级语义特征（物体形状、空间布局、功能性），这些特征在很大程度上不受输入模态影响。

C. 效率优势

仅 10K 可训练参数，我们的方法比此前纯深度分类方法少使用 3,000–6,000 倍参数，非常适合资源受限场景和快速原型开发。

D. 局限性

数据集较小 (1,449 张)，结论可能不推广到更大数据集。仅评估冻结特征，微调 DINOv2 可获更高精度。

VI. 结论

我们确立了 DINOv2 线性探测作为 NYU Depth V2 上纯深度场景分类的新最先进水平。冻结 DINOv2-Base + 10K 参数线性头达到 55.5% Top-1 准确率——超越此前公开的纯深度分类结果 (33.2%–42.6%) 12.9–22.3 个百分点，而可训练参数比全网络微调方法少 3,000–6,000 倍。

REFERENCES

- [1] M. Oquab, T. Darcet, T. Moutakanni, *et al.*, “DINOv2: Learning Robust Visual Features without Supervision,” *Transactions on Machine Learning Research*, 2024.
- [2] N. Silberman, D. Hoiem, P. Kohli, and R. Fergus, “Indoor Segmentation and Support Inference from RGBD Images,” in *Proc. European Conference on Computer Vision (ECCV)*, 2012.
- [3] S. Gupta, R. Girshick, P. Arbeláez, and J. Malik, “Learning Rich Features from RGB-D Images for Object Detection and Segmentation,” in *Proc. European Conference on Computer Vision (ECCV)*, 2014.
- [4] K. He, G. Gkioxari, P. Dollár, and R. Girshick, “Mask R-CNN,” in *Proc. IEEE Int. Conf. Computer Vision (ICCV)*, 2017.
- [5] A. Wang, J. Lu, J. Cai, *et al.*, “Unsupervised Joint Feature Learning for Zero-shot Scene Classification,” arXiv:1609.00245, 2016.
- [6] A. Wang, J. Lu, J. Cai, *et al.*, “Indoor Scene Recognition in 3D,” in *Proc. Int. Conf. 3D Vision (3DV)*, 2016.
- [7] J. Hoffman, S. Gupta, and T. Darrell, “Learning Deep Representations for Scene Recognition on Depth Data,” in *Proc. IEEE Int. Conf. Robotics and Automation (ICRA)*, 2016.
- [8] A. Radford, J. W. Kim, C. Hallacy, *et al.*, “Learning Transferable Visual Models From Natural Language Supervision,” in *Proc. Int. Conf. Machine Learning (ICML)*, 2021.
- [9] G. Alain and Y. Bengio, “Understanding intermediate layers using linear classifier probes,” in *ICLR Workshop*, 2017.
- [10] Mar-Ding, “Depth Scene Classification: Project Summary,” Technical report, 2026. <https://github.com/Mar-Ding/depth-scene-classification>