

CLIP 跨模态传感器适配

Cross-modal Sensor Adaptation with CLIP

Mar-Ding

2026-06-10

Contents

项目简介	1
目标	1
动机	1
方法	2
管道	2
关键设计	2
与 Vision Banana 的联系	2
数据集	2
NYU Depth V2	2
实验结果	2
最优配置	2
消融实验汇总	3
各类别表现	3
核心结论	3
下一步方向	3
环境与代码	4

项目简介

目标

利用预训练视觉模型 CLIP 的图文对齐能力，通过轻量适配器实现深度传感器数据的零样本场景分类。即：输入深度图，输出场景类别（如 kitchen、bedroom、office 等 27 类室内场景）。

动机

- 深度/雷达传感器缺少大规模预训练模型
- 传统方案需为每个传感器重新训练完整模型，成本高
- CLIP 等预训练视觉模型内化了通用视觉知识，通过轻量适配即可泛化

方法

管道

深度图 → 重复3通道(伪RGB) → CLIP ViT编码器(冻结) → MLP Adapter → 文本类别匹配

关键设计

组件	说明
CLIP 模型	openai/clip-vit-base-patch32, 冻结全部参数
MLP Adapter	2 层全连接 (512→512→512), LayerNorm, ReLU, Dropout=0.2
可训练参数	528,384 (仅 Adapter)
损失函数	NT-Xent 对比损失 (温度 $\tau=0.07$)
优化器	AdamW, LR=5e-4, Weight Decay=1e-3

与 Vision Banana 的联系

Vision Banana (Google, 2026, arXiv:2604.20329) 提出：**图像生成预训练本身就是通用视觉学习器**——扩散模型通过指令微调可在分割、深度估计等任务上达到 SOTA。我们的工作与之互补：CLIP（对比式）做分类，而非生成。两者共同验证了“预训练视觉模型可作为通用特征提取器”这一趋势。

数据集

NYU Depth V2

项目	说明
样本数	1449 组 RGB-Depth 对
尺寸	深度图 640×480, RGB 图 480×640
场景	27 种室内场景 (bedroom, kitchen, bathroom, office 等)
格式	MATLAB v7.3 (.mat, 2.97GB, h5py 读取)
划分	900 训练 / 200 验证 / 249 测试

实验结果

最优配置

指标	数值
Zero-shot Top-1	25.30%
Zero-shot Top-5	48.19%
RGB Baseline (CLIP)	27.71%
相对 RGB 性能	91.3%
随机猜测 Top-1	3.7%

指标	数值
参数总量	528K

对比 Vision Banana：我们的参数量仅为其极小一部分（528K vs 完整扩散模型），专注分类任务，在深度 zero-shot 场景分类上达到 RGB 上限的 91%。

消融实验汇总

变量	Top-1	结论
基线 (MLP/600 样本)	19.50%	过拟合
Cross-Attention (3.8M)	12.05%	参数过多，欠拟合
最优 (LR=5e-4)	25.30%	更稳定的收敛
3 层 MLP	16.06%	更深反而不行
Dropout=0.3	18.47%	过度正则化
Temperature=0.1	18.88%	损失不够锐利
Prompt Ensemble	24.10%	无明显收益

各类别表现

类别	准确率	说明
bathroom	58.8%	结构独特，易于区分
bookstore	50.0%	少样本但特征明显
kitchen	46.7%	大量样本，稳定性好
classroom	33.3%	少样本
bedroom	18.2%	一般
living_room	11.1%	与多类混淆

核心结论

1. **轻量跨模态适配可行**—仅 528K 参数即可让深度图实现 zero-shot 场景分类
2. **与 Vision Banana 趋势一致**—预训练视觉模型可作为通用特征提取器
3. **深度可达 RGB 性能的 91%**—但进一步受限于纯几何信息的天花板
4. **MLP Adapter 优于复杂结构**—在小数据量下，简单模型反而更好

下一步方向

- 数据增强（旋转/缩放/裁剪深度图）
- 更大 CLIP Backbone (ViT-L/14)
- 真实雷达数据验证
- 多模态融合（深度 + RGB）

环境与代码

项目	说明
GPU	NVIDIA RTX 4060 Laptop (CUDA 12.1)
框架	PyTorch 2.5.1 + Transformers 4.47.1
代码	github.com/Mar-Ding/cross-modal-clip
训练时间	~5 分钟 (25 epochs)